

LAPORAN HASIL DATA ANALYST

Analisis Data Hubungan *Screen Time* dan Interaksi Sosial Terhadap Tingkat Stres Remaja

Nama Perusahaan : Kaggle Open Dataset (Social Media
Impact on Teen Mental Health)
Nama Data Analyst : Alka Tadra Koswara
NPM : 10122136
Jenjang/Program Studi : S1/Sistem Informasi
Tanggal Laporan : 5 Juni 2025

Laporan Hasil Data Analyst ini Dibuat

Dalam Rangka Bukti Portofolio sebagai Data Analyst

DAFTAR ISI

DAFTAR ISI	3
1. PENDAHULUAN	4
1.1 Latar Belakang	4
1.2 Tujuan Analisis	4
2.1 Masalah atau peluang bisnis yang ditemukan	6
2.2 Pertanyaan Utama Analisis	6
3. PENGUMPULAN & PERSIAPAN DATA	7
3.1 Sumber Data	7
3.2 Proses Praproses	8
4. ANALISIS DATA	15
4.1 Eksplorasi Variabel Utama	15
4.2 Visualisasi Data	15
6. PELUANG BISNIS	21
7. KESIMPULAN DAN REKOMENDASI	22
7.1 Kesimpulan	22
7.2 Rekomendasi	22
LAMPIRAN-LAMPIRAN	23

1. PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi digital dan media sosial telah menjadi bagian yang tidak terpisahkan dari gaya hidup remaja modern. Meskipun teknologi memberikan kemudahan akses informasi dan komunikasi, intensitas penggunaan layar (*screen time*) dan media sosial yang tidak terkontrol kerap dihubungkan dengan penurunan kualitas kesehatan fisik maupun psikologis. Pola hidup seperti durasi tidur yang tidak teratur, kurangnya aktivitas fisik, dan rendahnya interaksi sosial di dunia nyata diyakini memiliki kontribusi signifikan terhadap peningkatan tingkat stres, kecemasan (*anxiety*), dan risiko depresi pada remaja.

Untuk membuktikan asumsi tersebut secara empiris, diperlukan sebuah pendekatan *Data Analytics* yang komprehensif. Pengolahan dataset "Teen Mental Health", yang diakses secara publik melalui Kaggle pada tautan ini <https://www.kaggle.com/datasets/algozee/teenager-menthal-healy/data>, ini dilakukan untuk mengekstraksi wawasan (*insight*) tersembunyi dari sekumpulan data mentah yang merekam kebiasaan hidup dan metrik kesehatan mental remaja. Selain untuk mengukur korelasi antar variabel, proses analisis ini juga diimplementasikan sebagai bentuk pembuktian kompetensi teknis dalam menerapkan siklus pengolahan data standar *industry* mulai dari penelaahan kelayakan data, pembersihan anomali (*data cleaning*), transformasi bentuk data (*encoding*), hingga pembuatan visualisasi informasi (*Business Intelligence*).

1.2 Tujuan Analisis

- **Melakukan Pembersihan Data (*Data Cleaning*):** Menangani masalah integritas pada data mentah, seperti menghapus baris duplikat, menangani nilai kosong (*missing values*), serta mengeliminasi data anomali (*outlier*) pada variabel umur dan durasi tidur agar tidak menimbulkan bias pada hasil akhir.
- **Mengkonstruksi Data (*Feature Preparation*):** Menerapkan teknik standarisasi teks dan *encoding* untuk mengonversi variabel kategorikal menjadi representasi numerik

sehingga dataset sepenuhnya siap diproses secara matematis.

- **Eksplorasi dan Visualisasi Data (*Exploratory Data Analysis*):** Menganalisis dan memvisualisasikan korelasi antara variabel gaya hidup (durasi media sosial, jam tidur, tingkat interaksi sosial) terhadap indikator kesehatan mental (tingkat stres, kecemasan, dan label depresi).
- **Menyajikan Wawasan Pendukung Keputusan:** Menghasilkan informasi berbasis data (*data-driven*) yang valid dan representatif, yang dapat dipahami dengan mudah oleh pemangku kepentingan untuk mendukung penyusunan kebijakan terkait literasi digital remaja.

2.IDENTIFIKASI KEBUTUHAN BISNIS

2.1 Masalah atau peluang bisnis yang ditemukan

Masalah Utama: Terdapat fenomena peningkatan masalah kesehatan mental pada demografi remaja seperti tingginya tingkat stres, kecemasan (*anxiety*), dan potensi depresi. Fenomena ini diyakini berkaitan erat dengan perubahan gaya hidup digital, khususnya durasi penggunaan media sosial yang tidak terkontrol, tingginya paparan layar (*screen time*) menjelang tidur, serta rendahnya partisipasi dalam aktivitas fisik dan interaksi sosial secara langsung.

Peluang Bisnis / Implikasi Manajerial: Melalui pengolahan dataset rekam jejak perilaku remaja ini, dapat diidentifikasi pola sebab-akibat yang konkret berdasarkan data (*data-driven*). Wawasan ini membuka peluang bagi pemangku kepentingan seperti institusi pendidikan, penyedia layanan konseling, maupun pengembang teknologi (*parental control apps*) untuk menciptakan intervensi yang tepat sasaran. Contoh tindak lanjutnya meliputi penyusunan program peningkatan interaksi sosial di sekolah atau pembuatan panduan batasan waktu layar maksimal harian guna meminimalisasi risiko depresi.

2.2 Pertanyaan Utama Analisis

Untuk memastikan proses analisis data tetap fokus dan selaras dengan penyelesaian masalah operasional, dirumuskan beberapa pertanyaan metrik utama sebagai berikut:

- Bagaimana distribusi atau proporsi remaja yang terindikasi masuk ke dalam kategori depresi (*depression_label*) pada populasi dataset ini?
- Apakah terdapat perbedaan rata-rata tingkat stres (*stress_level*) yang signifikan berdasarkan klasifikasi tingkat interaksi sosial remaja (*social_interaction_level*)?
- Sejauh mana kekuatan korelasi antara kebiasaan konsumsi digital (durasi media sosial harian dan *screen time* sebelum tidur) terhadap kualitas jam tidur (*sleep_hours*) dan tingkat kecemasan (*anxiety_level*)?
- Platform media sosial apakah (*platform_usage*) yang paling dominan digunakan oleh para remaja setelah dilakukan proses penyeragaman dan pembersihan redundansi data?

3. PENGUMPULAN & PERSIAPAN DATA

3.1 Sumber Data


Disini saya mengambil dataset dari kaggle dan format file nya berupa .CSV dan ini adalah penjelasan dari saya.

```
import pandas as pd
# 1. Load dataset awal
df = pd.read_csv['/content/Teen_Mental_Health_Dataset_DIRUSAK.csv']
```

Bayangkan kita memiliki ribuan lembar kertas kuesioner berisi jawaban dari para remaja yang tersimpan rapat di dalam sebuah lemari arsip (dalam bentuk *file* komputer). Agar kertas-kertas ini bisa kita baca, periksa, dan rapikan, kita harus memindahkannya terlebih dahulu dari lemari arsip ke atas "meja kerja" kita.

Screenshot kode di atas adalah instruksi awal yang kita berikan kepada komputer untuk melakukan tugas tersebut. Secara sederhana, kita memerintahkan komputer untuk mengambil kumpulan data mentah tersebut dan menggelarnya di atas meja kerja virtual kita (yang disebut sebagai tabel *DataFrame*). Setelah semua data ini berhasil terbuka dan dapat dilihat oleh sistem, barulah kita bisa memulai proses selanjutnya, yaitu memeriksa kelengkapan dan menyingkirkan data-data yang rusak.

- Hasil dari dataset yang kita ambil



	age	gender	daily_social_media_hours	platform_usage	sleep_hours	screen_time_before_sleep	academic_performance	physical_activity	social_interaction_
0	14	male	7.9	Instgrm	7.4	2.9	3.01	1.5	
1	19	female	1.9	TikTok	8.0	2.9	3.22	0.8	
2	17	female	1.3	Instagram	7.6	0.5	3.92	0.0	
3	15	male	7.4	tik_tok	6.9	1.6	3.48	0.8	m
4	15	female	4.7	BOTH	4.9	3.0	2.37	1.4	m
...	...	...	...	...	...	...	...	...	...
1255	16	female	3.1	TikTok!!!	5.0	1.1	2.73	1.6	
1256	19	female	NaN	NaN	NaN	0.8	NaN	0.5	
1257	18	male	5.7	Both	8.4	2.4	2.84	0.7	
1258	18	male	3.1	Instgrm	5.7	2.9	3.10	0.6	m
1259	19	male	7.7	instagram	4.2	2.6	2.20	1.8	

Disini kita melihat banyak sekali kesalahan dalam data tersebut, kita ambil pada kolom (platform_usage) disitu kita melihat banyak sekali kata yang *typo* seperti instagram menjadi Instgrm, penulisan Tik Tok menjadi tik_tok. Selanjutnya ada baris yang berisi data NaN, kita bisa melihat di baris 1256 dengan gender female disitu banyak kolom kolom dengan data NaN, oleh karena itu data NaN tidak bisa diolah oleh komputer. Dan disini banyak ada banyak data dengan total jumlah baris awal sebelum dibersihkan: 1260

3.2 Proses Praproses

Disini tahap untuk membersihkan dataset kita dari anomali anomali yang terdapat pada dataset kita, seperti yang penulis sudah jelaskan bahwa banyak sekali data yang salah mulai dari typo, NaN, dan data tidak mungkin terjadi seperti total jam tidur berada di 99jam, berikut tahapan – tahapan yang saya lakukan pada dataset tersebut.

- Pemeriksaan dan penghapusan data kosong

```
# Menghitung Data Kosong dan Duplikat
print(f"Jumlah baris awal sebelum dibersihkan: {len(df)}\n")

# --- Proses Missing Values (Data Kosong) ---
missing_count = df.isnull().any(axis=1).sum()
print(f"[-] Jumlah baris dengan data kosong (NaN) yang dihapus: {missing_count}")
df = df.dropna()
print(f"[>] Sisa baris setelah data kosong dihapus: {len(df)}\n")
```

```
[-] Jumlah baris dengan data kosong (NaN) yang dihapus: 151
[>] Sisa baris setelah data kosong dihapus: 1109
```

Dalam proses pengisian kuesioner, terkadang responden tidak sengaja melewati pertanyaan yang seharusnya diisi. Hal ini menghasilkan data kosong, atau yang dalam komputasi dikenal sebagai *Missing Values* (NaN). Keberadaan nilai NaN ini akan menjadi kendala karena algoritma analisis data tidak dapat memproses entri yang kosong. Oleh karena itu, dilakukan deteksi dan penghapusan baris data yang memiliki nilai NaN menggunakan bahasa pemrograman Python. Berdasarkan hasil deteksi menggunakan fungsi dropna(), ditemukan dan dihapus sebanyak Jumlah baris dengan data kosong (NaN) yang dihapus: 151 baris data kosong.

- Cek Outlier

```
# Tampilkan total data sebelum masuk ke tahap IQR
print(f"Total data sebelum proses eliminasi IQR: {len(df)}\n")

# 5. Penanganan Outlier menggunakan metode IQR (Interquartile Range)
def hapus_outlier_iqr(df_input, kolom):
    print(f"--- Proses Outlier pada kolom '{kolom}' ---")

    Q1 = df_input[kolom].quantile(0.25)
    Q3 = df_input[kolom].quantile(0.75)
    IQR = Q3 - Q1
    batas_bawah = Q1 - 1.5 * IQR
    batas_atas = Q3 + 1.5 * IQR

    # Cari baris yang merupakan outlier
    outlier_kondisi = (df_input[kolom] < batas_bawah) | (df_input[kolom] > batas_atas)
    jumlah_outlier = outlier_kondisi.sum()

    print(f"Nilai Q1: {Q1:.2f} | Nilai Q3: {Q3:.2f}")
    print(f"Batas Bawah: {batas_bawah:.2f} | Batas Atas: {batas_atas:.2f}")
    print(f"[-] Jumlah Outlier yang dihapus: {jumlah_outlier}")

    # Kembalikan dataframe tanpa outlier
    df_bersih = df_input[~outlier_kondisi]
    print(f"[>] Sisa baris data saat ini: {len(df_bersih)}\n")

    return df_bersih

# Eksekusi fungsi IQR ke variabel numerik utama
df = hapus_outlier_iqr(df, 'sleep_hours')
df = hapus_outlier_iqr(df, 'age')
df = hapus_outlier_iqr(df, 'daily_social_media_hours')

# Tampilkan sisa data bersih akhir
print(f"=== TOTAL BARIS DATA BERSIH AKHIR: {len(df)} ===")
```

Outlier adalah nilai pengamatan yang menyimpang sangat jauh dari kumpulan observasi lainnya. Dalam dataset ini, ditemukan beberapa respons tidak wajar, seperti umur dengan nilai negatif atau durasi tidur ekstrem hingga 99 jam sehari. Anomali semacam ini harus disaring agar tidak menciptakan bias dan merusak distribusi nilai rata-rata responden secara keseluruhan.

Untuk menangani *outlier* secara objektif dan terukur, dilakukan perhitungan statistik menggunakan metode *Interquartile Range* (IQR). Metode ini mendeteksi nilai ekstrem dengan memanfaatkan kuartil bawah (Q1) dan kuartil atas (Q3). Rentang antarkuartil (IQR) dihitung menggunakan persamaan berikut:

$$IQR = Q3 - Q1$$

Setelah nilai IQR diketahui, batas kewajaran data dievaluasi dengan menentukan ambang batas bawah dan batas atas:

$$BatasBawah = Q1 - (1.5 \times IQR)$$

$$BatasAtas = Q3 + (1.5 \times IQR)$$

Nilai yang berada di luar rentang batas tersebut dieksekusi oleh program sebagai pencilan dan dihapus dari kumpulan data. Penerapan metode IQR pada variabel numerik utama memberikan hasil sebagai berikut:

- Durasi Tidur (*sleep_hours*): Distribusi data menghasilkan nilai Q1 sebesar 5.20 dan Q3 sebesar 7.80. Berdasarkan perhitungan, batas bawah adalah 1.30 dan batas atas 11.70. Sistem berhasil mendeteksi dan mengeliminasi sebanyak 44 baris data.
- Usia (*age*): Dari perhitungan distribusi umur responden, didapatkan nilai Q1 = 14.00 dan Q3 = 18.00. Data yang berada di luar ambang batas kewajaran dengan batas bawah 8.00 dan batas atas 24.00 telah disaring, sehingga sebanyak 40 baris data berhasil dibersihkan.
- Durasi Media Sosial (*daily_social_media_hours*): Analisis pada variabel ini menunjukkan nilai Q1 = 2.70 dan Q3 = 6.40. Dengan batas bawah -2.85 dan batas atas 11.95, sebanyak 0 baris pencilan dihapus.

Secara sederhana, tahap penanganan *outlier* ini adalah proses membersihkan kumpulan data dari jawaban-jawaban responden yang aneh, tidak masuk akal, atau kemungkinan salah ketik misalnya mengaku tidur 99 jam sehari atau berumur minus. Agar penghapusan data ini objektif dan bukan sekadar tebak-tebakan, kita menggunakan rumus matematika standar untuk menentukan 'batas wajar' dari sebuah jawaban. Hasil dari penyaringan ini menunjukkan bahwa ada 44 jawaban durasi tidur dan 40 jawaban usia yang terdeteksi di luar batas wajar, sehingga harus kita buang. Sementara itu, untuk pertanyaan durasi bermain media sosial, seluruh jawaban responden masih tergolong wajar. Dengan membuang jawaban-jawaban ekstrem tersebut, kita memastikan bahwa hasil akhir analisis kita nanti benar-benar akurat, bisa dipercaya, dan tidak rusak hanya karena segelintir jawaban iseng.

- Standardisasi format kolom (huruf kecil, strip whitespace)

```
# 4. GANTI/TAMBAHKAN: Standardisasi string pada kolom 'platform_usage'
# Mengubah semua teks menjadi huruf kecil agar seragam
df['platform_usage'] = df['platform_usage'].str.lower()
# Menggabungkan kategori yang maknanya sama
df['platform_usage'] = df['platform_usage'].replace({
    'instgrm': 'instagram',
    'instagram!!!': 'instagram',
    'tik_tok': 'tiktok',
    'tiktok!!!': 'tiktok',
    'both!!!': 'both'
})
```

Jadi setiap orang punya gaya mengetik yang berbeda. Ada yang menulis aplikasi dengan gaya "TikTok", "tik_tok", atau bahkan "tiktok!!!". Bagi manusia, maknanya sama, namun bagi komputer itu adalah tiga hal yang berbeda. Kita harus merapikan dan menyeragamkan semua teks tersebut menjadi huruf kecil semua dan menghapus tanda baca yang tidak penting. Oleh karena itu kita harus mengganti format kolom.

- Deteksi dan penghapusan data duplikat

```
# --- Proses Data Duplikat ---
duplicate_count = df.duplicated().sum()
print(f"[-] Jumlah baris duplikat yang dihapus: {duplicate_count}")
df = df.drop_duplicates()
print(f"[>] Sisa baris setelah data duplikat dihapus: {len(df)}\n")
```

```
[-] Jumlah baris duplikat yang dihapus: 53
[>] Sisa baris setelah data duplikat dihapus: 1056
```

Data duplikat adalah rekaman observasi yang muncul lebih dari satu kali dengan nilai yang identik di seluruh variabelnya. Dalam proses pengumpulan data, salinan ganda ini sering terjadi akibat kesalahan teknis sistem, proses penggabungan data (merging), atau pengiriman formulir yang berulang oleh responden. Keberadaan data ganda ini harus disaring karena dapat memberikan bobot berlebih pada observasi tertentu, memicu bias, dan menurunkan tingkat akurasi serta validitas model yang akan dibangun.

Untuk menangani duplikasi ini secara terukur, dilakukan pemindaian baris secara menyeluruh menggunakan fungsi identifikasi duplikat pada *dataframe*. Algoritma mengevaluasi setiap entri dan mencatat indeks baris yang memiliki nilai yang sama persis

dengan baris yang telah muncul sebelumnya.

Penerapan metode pembersihan ini pada kumpulan data memberikan hasil sebagai berikut:

- Identifikasi Duplikat: Sistem berhasil mendeteksi sebanyak 53 baris data yang identik.
- Sisa Data Bersih: Setelah baris yang berulang tersebut dihapus secara permanen menggunakan perintah eliminasi duplikat, kumpulan data menyisakan total 1056 baris observasi unik yang siap digunakan untuk tahapan analisis selanjutnya.

Secara sederhana, tahap penanganan data duplikat ini ibarat kita sedang menyortir tumpukan formulir kuesioner secara manual, lalu menemukan ada beberapa lembar jawaban yang isinya sama persis karena mesin *fotocopy* tidak sengaja menggandakannya, atau karena satu responden mengirimkan jawaban yang sama dua kali. Tentu saja, kita hanya membutuhkan satu formulir untuk mewakili satu kejadian atau satu responden tersebut. Jika kita tetap memasukkan semua salinannya, hasil perhitungan akhir kita nanti akan tidak seimbang karena data tersebut dihitung berkali-kali. Oleh karena itu, kita membuang salinan yang berlebih dan hanya menyimpan versi aslinya. Dengan memastikan setiap data benar-benar unik dan tidak ada yang berulang, kita menjaga agar hasil analisis kita nanti lebih adil, representatif, dan terhindar dari kesimpulan yang menyesatkan.

- Dimensi Akhir Dataset (Bebas NaN, Duplikat, & *Outlier*)

```
# 6. Cek dimensi akhir dataset yang sudah bersih  
print("Dimensi dataset setelah data cleaning:", df.shape)
```

```
Dimensi dataset setelah data cleaning: (972, 13)
```

Pada tahap ini adalah memvalidasi dimensi dari kumpulan data yang telah diproses. Pengecekan ini krusial untuk mengonfirmasi bentuk dan ukuran data mutakhir sebelum memasuki tahapan analisis lanjutan atau pemodelan algoritma. Pengecekan dimensi menggunakan parameter `shape` memberikan informasi mengenai jumlah observasi (baris) dan jumlah variabel (kolom) yang tersisa. Hasil dari proses ini adalah sebagai berikut:

- Data setelah terhindar dari NaN, Duplicate, dan outlier: Berdasarkan eksekusi program pada tahap akhir pembersihan, struktur data menyisakan dimensi sebanyak 972 baris

observasi dan 13 kolom atribut/fitur.

Secara sederhana, tahap ini adalah momen di mana kita menghitung kembali total "bahan baku" yang sudah benar-benar bersih dan siap untuk "dimasak" atau dianalisis. Bayangkan kumpulan data ini seperti sebuah tabel besar di buku catatan atau Microsoft Excel. Kolom mewakili jenis pertanyaan atau informasi yang kita kumpulkan (dalam hal ini ada 13 jenis informasi), sedangkan baris mewakili jumlah responden atau kejadian yang kita catat.

Setelah kita membuang lembar kuesioner yang tidak diisi penuh (NaN), menyingkirkan lembaran yang tercetak ganda (duplikat), dan mengeliminasi jawaban-jawaban yang tidak masuk akal (outlier), kini kita memiliki tepat 972 lembar jawaban yang benar-benar berkualitas tinggi. Angka inilah yang menjadi pondasi akhir kita, memastikan bahwa kesimpulan yang kita ambil nanti didasarkan pada data yang solid, valid, dan bebas dari kecacatan.

- Format tanggal dan konversi tipe data

```
# 7. MENINGKATKAN DATA (Feature Encoding)
# Mengubah variabel kategorikal menjadi numerik agar bisa diproses algoritma

# a. Ordinal Encoding untuk 'social_interaction_level'
# Menggunakan urutan karena ada tingkatan: low (0), medium (1), high (2)
mapping_social = {'low': 0, 'medium': 1, 'high': 2}
df['social_interaction_level'] = df['social_interaction_level'].map(mapping_social)

# b. Binary Encoding untuk 'gender'
# Mengubah teks menjadi biner: female (0) dan male (1)
mapping_gender = {'female': 0, 'male': 1}
df['gender'] = df['gender'].map(mapping_gender)

# c. One-Hot Encoding untuk 'platform_usage'
# Karena platform tidak ada tingkatan (Instagram tidak lebih tinggi dari TikTok),
# kita pecah menjadi kolom biner terpisah menggunakan get_dummies
df = pd.get_dummies(df, columns=['platform_usage'], dtype=int)

# Menampilkan 5 baris teratas untuk memverifikasi perubahan
df.head()
```

Dalam himpunan data yang digunakan, tidak terdapat variabel berbentuk temporal atau tanggal, sehingga tahapan konstruksi data difokuskan sepenuhnya pada transformasi tipe data kategorikal (*Feature Encoding*). Secara fundamental, algoritma *machine learning* dan pemodelan statistik memerlukan masukan (*input*) berformat numerik. Oleh karena itu,

atribut-atribut yang masih berwujud teks harus dikonversi menjadi representasi matematis.

Berdasarkan struktur data yang ada, transformasi ini dilakukan melalui tiga pendekatan yang disesuaikan dengan karakteristik masing-masing variabel:

- Ordinal Encoding: Diterapkan pada variabel `social_interaction_level` karena memiliki hierarki atau tingkatan yang logis. Nilai tekstual dipetakan ke dalam urutan berbobot: tingkat '*low*' menjadi 0, '*medium*' menjadi 1, dan '*high*' menjadi 2.
- Binary Encoding: Digunakan pada variabel `gender` untuk mengubah nilai kategorikal ganda menjadi format biner, di mana representasi '*female*' dikonversi menjadi angka 0 dan '*male*' menjadi angka 1.
- One-Hot Encoding: Diimplementasikan pada variabel `platform_usage` karena data ini bersifat nominal (tidak memiliki tingkatan; misalnya Instagram tidak memiliki nilai hierarki yang lebih tinggi dari TikTok). Menggunakan fungsi `get_dummies`, variabel ini dipecah menjadi beberapa kolom terpisah untuk setiap *platform*, di mana entri datanya hanya berisi angka 1 (jika menggunakan) atau 0 (jika tidak).

Secara sederhana, komputer pada dasarnya adalah sebuah kalkulator raksasa yang buta terhadap huruf dan hanya paham bahasa angka. Komputer tidak bisa membedakan teks "Tinggi", "Perempuan", apalagi membandingkan "Instagram" dan "TikTok". Oleh karena itu, kita bertugas menjadi penerjemah. Jawaban responden yang tadinya berupa kata-kata, kita ubah menjadi simbol angka.

Jika jawabannya bertingkat (seperti tingkat interaksi), kita beri nilai berurut 0, 1, dan 2. Namun, jika jawabannya setara dan tidak ada yang "lebih hebat" dari yang lain (seperti pilihan jenis media sosial), kita pecah menjadi kolom-kolom baru yang sekadar diisi dengan status 'Ya' (angka 1) atau 'Tidak' (angka 0). Proses penerjemahan ini ibarat menyiapkan bahan makanan yang sudah dipotong dan ditakar dengan pas, sehingga mesin komputer kita nantinya bisa langsung memproses dan menghitung rumus-rumus statistiknya tanpa kendala.

4. ANALISIS DATA

4.1 Eksplorasi Variabel Utama


Pada tahap ini kita seperti mendapat banyak sekali informasi. Agar tidak bingung, kita perlu menyaring informasi tersebut dan membaginya ke dalam dua kelompok besar, yaitu "Sebab" dan "Akibat". Kelompok pertama adalah faktor "Sebab" atau kebiasaan sehari-hari mereka. Ini meliputi berapa lama mereka bermain media sosial, durasi tidur setiap malam, kebiasaan menatap layar HP sebelum memejamkan mata, hingga seberapa sering mereka asyik bergaul langsung dengan teman-temannya di dunia nyata.

Jika kita mendapat informasi yang sangat banyak kita menentukan fokus utama pada analisis ini, variabel (kolom) utama yang kita eksplorasi dibagi menjadi dua kelompok besar yaitu :

- Variabel kebiasaan & Gaya Hidup (Penyebab/Faktor): Meliputi seberapa lama remaja menggunakan media sosial (`daily_social_media_hours`), durasi tidur (`sleep_hours`), lama menatap layar sebelum tidur (`screen_time_before_sleep`), dan tingkat keaktifan mereka dalam berinteraksi sosial di dunia nyata (`social_interaction_level`).
- Variabel Kesehatan Mental (Dampak/Hasil): Meliputi tingkat stres (`stress_level`), tingkat kecemasan (`anxiety_level`), dan penanda apakah remaja tersebut masuk ke dalam kategori depresi atau tidak (`depression_label`).

4.2 Visualisasi Data

- Memastikan tidak ada data duplikat



Kartu Skor (Total Data Bersih)

Gambar di atas menampilkan sebuah komponen visual dasar yang dikenal sebagai *Scorecard* (Kartu Skor). Pada visualisasi tersebut, indikator *Record Count* menunjukkan angka 972, yang merepresentasikan total baris data atau jumlah responden yang akan digunakan dalam

tahap analisis akhir.

Dalam perspektif teknologi informasi, angka ini bukanlah sekadar jumlah data mentah saat pertama kali dikumpulkan. Angka 972 ini merupakan hasil akhir setelah *dataset* melewati serangkaian fase *data cleaning* (pembersihan data) di dalam sistem. Pada fase tersebut, algoritma telah bekerja untuk mendeteksi dan menghapus anomali, seperti baris data yang kosong (*missing values*) maupun data responden yang tercatat lebih dari satu kali (duplikasi). Sederhananya, proses ini memastikan bahwa kita tidak menghitung orang yang sama dua kali atau memasukkan lembar kuesioner yang belum diisi. Dengan tercapainya angka 972 data bersih ini, kita dapat menjamin bahwa kualitas informasi yang digunakan sangat valid, sehingga seluruh grafik dan kesimpulan yang dihasilkan pada tahap selanjutnya bebas dari bias atau kesalahan perhitungan.

- Menampilkan Korelasi antar kolom untuk analisis data




Diagram Tencar (Korelasi Penggunaan Media Sosial dan Kecemasan)

Visualisasi di atas menggunakan jenis grafik yang dikenal dalam dunia pengolahan data sebagai *Scatter Plot* (Diagram Tencar). Dalam ilmu analisis data, instrumen ini secara khusus digunakan untuk mendeteksi dan memetakan ada atau tidaknya hubungan timbal balik (korelasi) antara dua variabel angka yang berbeda.

Pada arsitektur grafik tersebut, sumbu horizontal (X) merepresentasikan atribut `daily_social_media_hours` atau durasi penggunaan media sosial harian responden (dalam hitungan jam). Sementara itu, sumbu vertikal (Y) merepresentasikan `anxiety_level` atau skala tingkat kecemasan yang dirasakan responden. Secara sederhana, setiap satu titik biru yang menyebar pada ruang grafik tersebut mewakili rekam jejak kondisi satu orang remaja, yang dipetakan berdasarkan kebiasaan jam tidur mereka (`sleep_hours`).

Jika kita mengamati pola kumpulan titik-titik tersebut secara keseluruhan, terlihat bahwa sebaran datanya memiliki kecenderungan bergerak menanjak ke arah kanan atas. Dalam terminologi statistika data, pola pergerakan ini diidentifikasi sebagai korelasi positif. Penjelasan praktis dari temuan ini sangatlah jelas: terdapat hubungan yang searah antara kedua kebiasaan tersebut, di mana semakin banyak waktu yang dihabiskan seorang remaja di depan layar media sosial setiap harinya, maka semakin tinggi pula risiko tingkat kecemasan yang cenderung mereka alami.

- Menampilkan hasil visualisasi analisis dengan chart yang tepat

Menyajikan ratusan baris data berupa angka secara mentah tentu akan sangat membingungkan untuk dibaca. Oleh karena itu, sekumpulan data tersebut harus "diterjemahkan" ke dalam bentuk gambar atau grafik (*chart*). Dalam ilmu data, pemilihan jenis grafik tidak boleh dilakukan secara acak, melainkan harus disesuaikan secara presisi dengan karakteristik data dan tujuan informasi yang ingin dicapai. Penggunaan *chart* yang tepat sasaran ini berfungsi sebagai jembatan komunikasi, agar pola tersembunyi, perbandingan, hingga tren masalah kesehatan mental remaja dapat dipahami dengan cepat oleh siapa saja, bahkan tanpa perlu melakukan perhitungan manual.


Untuk menjawab kebutuhan tersebut, analisis ini menggunakan dua jenis visualisasi utama:

1. **Pie Chart (Diagram Lingkaran):** Digunakan secara khusus untuk melihat distribusi atau porsi pembagian kelompok secara keseluruhan (seperti proporsi tingkat interaksi sosial).
2. **Bar Chart (Diagram Batang):** Digunakan untuk mengukur dan membandingkan secara langsung jumlah kasus maupun tren rata-rata antar kelompok (seperti perbandingan jumlah kasus depresi dan rata-rata tingkat stres).

- **Diagram Lingkaran (Distribusi Tingkat Interaksi Sosial)**


Visualisasi pertama menggunakan Diagram Lingkaran atau *Pie Chart*. Secara fungsional dalam ilmu data, grafik ini sangat efektif untuk membedah komposisi atau proporsi dari sebuah kelompok besar. Pada kasus ini, diagram membagi seluruh responden ke dalam tiga

segmen berdasarkan tingkat keaktifan sosial mereka di dunia nyata: rendah (0), sedang (1), dan tinggi (2). Melalui visualisasi ini, kita dapat dengan cepat mengidentifikasi gaya hidup mana yang paling mendominasi populasi remaja saat ini. Pemetaan porsi ini sangat krusial sebagai fondasi awal sebelum kita menyelidiki lebih jauh bagaimana kebiasaan bergaul tersebut berdampak pada kesehatan mental mereka.




- **Diagram Batang Vertikal (Perbandingan Kasus Depresi)**

Untuk mengukur metrik kesehatan mental secara langsung, digunakan Diagram Batang (*Bar Chart*). Pemilihan grafik batang sangat ideal karena fungsinya yang secara tegas membandingkan kuantitas antar kategori. Pada diagram ini, sistem membandingkan dua kelompok populasi: remaja yang tidak menunjukkan gejala depresi (diwakili oleh label "0") dan remaja yang terindikasi mengalami gejala depresi (diwakili oleh label "1"). Tinggi rendahnya batang pada grafik ini secara instan memberikan gambaran nyata mengenai seberapa mengkhawatirkan skala masalah depresi yang sedang terjadi pada kelompok remaja dalam data ini.



- **Diagram Batang Modifikasi (Tren Rata-rata Tingkat Stres)**

Berbeda dengan diagram batang sebelumnya yang sekadar menghitung jumlah orang (kuantitas), diagram batang yang kedua ini telah dimodifikasi fungsi matematisnya untuk menampilkan nilai Rata-rata (*Average*). Grafik ini dirancang secara spesifik untuk menjawab satu hipotesis penting: *Apakah remaja yang jarang bergaul lebih rentan mengalami stres?* Dengan membandingkan tinggi batang rata-rata tingkat stres (*stress_level*) pada masing-masing kelompok interaksi sosial, kita dapat melihat tren yang jelas. Grafik ini membuktikan secara visual apakah gaya hidup yang menutup diri atau kurang bersosialisasi (label "0") benar-benar menjadi faktor penyumbang tingginya beban stres pada remaja.



Melalui pemetaan visual menggunakan Google Looker Studio, pola hubungan antara gaya hidup dan kesehatan mental remaja berhasil ditampilkan secara ringkas dan objektif. Penggunaan instrumen *Business Intelligence* ini terbukti efektif dalam menyederhanakan ratusan baris data mentah menjadi wawasan (*insight*) yang mudah dipahami oleh pembaca dari berbagai latar belakang.

5. TEMUAN & *INSIGHT*

Proses analisis data tidak sekadar menghasilkan deretan angka dan grafik yang statis, melainkan mengungkap rekam jejak perilaku digital responden yang secara nyata memengaruhi kesehatan psikologis mereka. Berdasarkan tahap pemrosesan data (*data processing*) dan pemodelan visual yang telah diuraikan pada bab sebelumnya, terdapat beberapa wawasan (*insight*) krusial yang berhasil diidentifikasi. Temuan ini menyoroti bagaimana kebiasaan berinteraksi dengan teknologi dan lingkungan sekitar berperan sebagai variabel pembentuk kondisi mental remaja saat ini:

- **Korelasi Positif Layar Digital dan Kecemasan:** Analisis membuktikan adanya hubungan yang selaras antara metrik penggunaan media sosial harian dengan tingkat kecemasan. Artinya, semakin tinggi durasi *screen time* (waktu menatap layar gawai) seorang remaja pada platform virtual, maka semakin rentan pula mereka mengalami gangguan kecemasan.
- **Interaksi Fisik sebagai Peredam Stres:** Pengolahan data menunjukkan anomali yang menarik, di mana kelompok remaja dengan tingkat interaksi sosial yang rendah justru memiliki rata-rata skor stres yang jauh lebih tinggi. Hal ini membuktikan bahwa interaksi di dunia nyata (bertemu dan bersosialisasi secara fisik) berfungsi sebagai mekanisme alami yang efektif untuk menurunkan beban pikiran, dan hal ini tidak bisa digantikan oleh obrolan teks di dunia maya.
- **Urgensi Pendeteksian Dini melalui Data:** Kehadiran label indikasi depresi pada sebagian kecil kumpulan data (*dataset*) menegaskan bahwa masalah kesehatan mental pada remaja bukanlah asumsi belaka. Ini adalah fakta yang terekam secara statistik dan membutuhkan intervensi atau penanganan sistematis dengan segera.

6. PELUANG BISNIS

Perkembangan teknologi informasi saat ini tidak hanya mengubah cara manusia berkomunikasi, tetapi juga memunculkan tantangan baru pada ranah kesehatan mental. Celah permasalahan yang ditemukan dari data di atas seperti tingginya tingkat stres akibat *screen time* berlebih dan minimnya sosialisasi justru membuka peluang strategis untuk inovasi bisnis digital. Pelaku industri atau perusahaan rintisan (*startup*) dapat memanfaatkan wawasan berbasis data ini untuk merancang solusi teknologi yang berfokus pada *digital wellbeing* (kesejahteraan pengguna di era digital). Berikut adalah beberapa prospek pengembangan produk yang sangat menjanjikan:

- **Pengembangan Aplikasi *Digital Wellbeing* Terintegrasi:** Terdapat peluang besar untuk merancang perangkat lunak (*software*) yang tidak hanya berfungsi memblokir media sosial saat batas waktu harian habis. Aplikasi ini dapat dirancang dengan algoritma cerdas yang merekomendasikan aktivitas fisik ringan atau hobi *offline* untuk mengalihkan perhatian pengguna dari gawai secara perlahan.
- **Platform Telekonseling *On-Demand*:** Membangun sebuah aplikasi layanan kesehatan mental dengan antarmuka pengguna (UI/UX) yang modern, ramah, dan tidak mengintimidasi bagi remaja. Platform ini dapat menjembatani remaja dengan psikolog profesional secara daring (*online*), sehingga mereka bisa mendapatkan pertolongan pertama secara anonim, aman, dan *real-time*.
- **Komunitas Berbasis *Event* (Pendekatan *Online-to-Offline* / *O2O*):** Melihat tingginya stres pada remaja yang jarang keluar rumah, pelaku bisnis dapat membangun platform manajemen acara (seperti lokakarya seni, olahraga, atau diskusi buku) yang mendorong remaja untuk mencari teman atau minat baru melalui aplikasi internet, untuk kemudian bertemu secara fisik di lokasi acara.

7. KESIMPULAN DAN REKOMENDASI

7.1 Kesimpulan

Berdasarkan keseluruhan alur pengolahan data pada laporan ini, dapat ditarik kesimpulan yang tegas bahwa arsitektur gaya hidup modern memiliki dampak langsung yang terukur terhadap penurunan kualitas kesehatan mental remaja. Ketergantungan yang berlebihan pada teknologi media sosial, jika tidak diimbangi oleh interaksi lingkungan yang memadai, terbukti menjadi katalis utama peningkatan beban stres dan kecemasan. Analisis ini menegaskan bahwa validasi virtual melalui layar ponsel tidak dapat menggantikan esensi dari interaksi sosial di dunia nyata dalam menjaga keseimbangan psikologis. Oleh karena itu, pendekatan penyelesaian masalah berbasis data (*data-driven problem solving*) sangat diperlukan untuk memitigasi fenomena ini secara objektif.

7.2 Rekomendasi

Menindaklanjuti kesimpulan di atas, diperlukan langkah-langkah solutif dan adaptif dari berbagai pihak yang terlibat. Rekomendasi berikut disusun untuk meminimalisasi dampak negatif dari teknologi, sekaligus mengoptimalkan potensi sistem informasi ke depannya:


- **Bagi Remaja (Pengguna Akhir):** Disarankan untuk mulai mengadopsi manajemen pembatasan waktu layar (*screen time management*) yang lebih disiplin dengan memanfaatkan fitur bawaan dari sistem operasi perangkat (*smartphone*), serta secara sadar meluangkan waktu untuk bersosialisasi di luar jaringan internet.
- **Bagi Institusi Pendidikan:** Diharapkan sekolah atau kampus dapat menggunakan wawasan dari data ini sebagai landasan dalam merancang program bimbingan konseling. Institusi pendidikan perlu memperbanyak kurikulum proyek kolaboratif tatap muka untuk memancing interaksi fisik antar siswa.
- **Bagi Pengembangan Sistem Selanjutnya:** Analisis dasar ini dapat ditingkatkan skalanya di masa depan. Misalnya, dengan mengintegrasikan teknologi *Machine Learning* (Pembelajaran Mesin) untuk membangun model prediksi (*predictive analytics*) yang mampu mendeteksi potensi kecenderungan depresi pada remaja secara otomatis berdasarkan log pola aktivitas digital mereka.

LAMPIRAN-LAMPIRAN

- Visualisasi tambahan

Sebagai data pendukung dari hasil analisis pada Bab 4, berikut dilampirkan tautan akses publik menuju *dashboard* interaktif Google Looker Studio. Melalui tautan ini, pembaca dapat meninjau seluruh hasil visualisasi secara langsung. Selain itu, dilampirkan pula tangkapan layar antarmuka (*interface*) pada mode "Edit" (*workspace*) sebagai bentuk validasi orisinalitas pengerjaan tata letak visualisasi.

- Tautan Dashboard Interaktif: <https://datastudio.google.com/s/naAb8o84Bak>
- Tangkapan Layar Mode Edit:



Setelah melalui tahapan pembersihan dan transformasi data, kumpulan data akhir divisualisasikan ke dalam sebuah *dashboard* analitik. *Dashboard* ini dirancang untuk memberikan ringkasan metrik (KPI) secara terpusat serta menyoroti pola perilaku,

demografi, dan status emosional responden melalui representasi grafis.

Berdasarkan *dashboard* yang telah dibangun, terdapat beberapa wawasan (*insights*) utama yang dapat ditarik:

- Indikator Metrik Rata-rata (KPI): Secara demografis, responden didominasi oleh kelompok usia remaja dengan rata-rata umur 16.09 tahun dan rata-rata performa akademik (IPK) sebesar 3.33. Dari segi kebiasaan, responden menghabiskan rata-rata 4.54 jam per hari di media sosial, dengan durasi waktu tidur rata-rata berada di angka 6.54 jam.
- Interaksi Sosial dan Emosi Dominan Berdasarkan Gender: Grafik batang pada bagian atas *dashboard* menunjukkan bahwa mayoritas responden, baik laki-laki maupun perempuan, berada pada tingkat interaksi sosial level *Low* (Rendah) dan *Medium* (Sedang). Pada metrik psikologis, *Sadness* (Kesedihan) dan *Anger* (Kemarahan) merupakan emosi yang paling dominan dirasakan, dengan responden perempuan mencatatkan frekuensi yang lebih tinggi pada emosi-emosi tersebut dibandingkan laki-laki.
- Dampak Penggunaan *Platform*: Melalui grafik batang dan *donut chart* pada bagian bawah, teridentifikasi bahwa Instagram dan TikTok adalah dua *platform* yang paling masif digunakan. Tingginya penggunaan kedua *platform* ini berkorelasi kuat dengan kelompok responden yang memiliki interaksi sosial rendah hingga sedang, dan memegang proporsi terbesar dalam distribusi emosi dominan secara keseluruhan.

Secara sederhana, *dashboard* ini ibarat sebuah "rapor kesehatan digital" yang merangkum ribuan baris data menjadi satu layar yang mudah dibaca. Tanpa harus pusing melihat tabel angka, kita bisa langsung menangkap cerita utama dari para responden ini. Kita bisa melihat rata-rata dari mereka adalah remaja usia 16 tahun yang nilai sekolahnya cukup bagus (IPK 3.3), tapi mereka menghabiskan nyaris 4,5 jam sehari untuk main *handphone* dan tidurnya hanya sekitar 6,5 jam.

Grafik-grafik di dalam *dashboard* ini mengungkapkan fakta yang cukup ironis: meskipun mereka sangat aktif menggunakan Instagram dan TikTok, interaksi sosial mereka di dunia nyata justru tergolong rendah. Selain itu, alih-alih merasa senang, emosi yang paling banyak

menyelimuti mereka adalah rasa sedih dan marah (terutama pada responden perempuan). Kesimpulannya, *dashboard* ini dengan sangat jelas memotret bagaimana tingginya paparan media sosial kekinian berpotensi membuat remaja semakin jauh dari interaksi dunia nyata dan rentan terhadap emosi negatif.

- Tabel statistik deskriptif

Variabel / Kolom	Count	Mean	Std	Min	25%	50%	75%	Max
age	972	15.92	2.03	13.00	14.00	16.00	18.00	19.00
gender	972	0.51	0.50	0.00	0.00	1.00	1.00	1.00
daily_social_media_hours	972	4.55	2.06	1.00	2.70	4.50	6.40	8.00
sleep_hours	972	6.45	1.44	4.00	5.20	6.50	7.63	9.00
screen_time_before_sleep	972	1.74	0.71	0.50	1.10	1.80	2.32	3.00
academic_performance	972	3.00	0.58	2.00	2.51	2.99	3.50	4.00
physical_activity	972	1.02	0.58	0.00	0.50	1.00	1.50	2.00
social_interaction_level	972	0.96	0.81	0.00	0.00	1.00	2.00	2.00
stress_level	972	5.52	2.92	1.00	3.00	5.00	8.00	10.00
anxiety_level	972	5.61	2.86	1.00	3.00	6.00	8.00	10.00
addiction_level	972	5.62	2.85	1.00	3.00	6.00	8.00	10.00
depression_label	972	0.02	0.16	0.00	0.00	0.00	0.00	1.00
platform_usage_both	972	0.06	0.23	0.00	0.00	0.00	0.00	1.00
platform_usage_instagram	972	0.06	0.24	0.00	0.00	0.00	0.00	1.00
platform_usage_tiktok	972	0.05	0.21	0.00	0.00	0.00	0.00	1.00
platform_usage_both	972	0.27	0.44	0.00	0.00	0.00	1.00	1.00
platform_usage_instagram	972	0.28	0.45	0.00	0.00	0.00	1.00	1.00
platform_usage_tiktok	972	0.28	0.45					

Dalam siklus *data analytics*, tabel ini berfungsi layaknya "profil ringkas" yang memetakan karakteristik dasar dari 972 baris data responden yang telah dibersihkan. Melalui indikator

pengukuran seperti nilai rata-rata (*mean*), simpangan baku (*std*), hingga batas nilai terendah (*min*) dan tertinggi (*max*), pembaca dapat langsung menangkap gambaran umum populasi tanpa harus meninjau lembaran data mentah satu per satu. Sebagai contoh praktis, dari tabel tersebut kita dapat langsung mengetahui bahwa rata-rata usia responden berada di angka 15,9 tahun, dengan kebiasaan penggunaan media sosial rata-rata mencapai 4,55 jam per hari.

- Potongan kode Python dari notebook

Bagian ini melampirkan beberapa potongan skrip pemrograman utama yang dieksekusi menggunakan bahasa Python (beserta *library Pandas*). Pemograman ini berfokus pada tahap *Data Pre-processing* (Praproses Data), khususnya tahapan untuk mengeliminasi data yang duplikat (*drop duplicates*) dan memastikan tidak ada nilai yang kosong (*missing values*) sebelum data diekspor ke platform visualisasi. secara keseluruhan dapat ditinjau lebih lanjut melalui repositori Google Colab pada tautan berikut: [Klik Disini](https://colab.research.google.com/drive/1B_zBLAjbQjqS7ZtWFtdtIFlbb7g2Kk9?usp=sharing) atau salin Link ini https://colab.research.google.com/drive/1B_zBLAjbQjqS7ZtWFtdtIFlbb7g2Kk9?usp=sharing